2440055351, Cindy Amanda Onggirawan, LB01, Final Exam COMP6745001- Machine Learning

Nomor 1: K-Nearest Neighbor

Import Libraries

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
import scipy.stats as stats
sns.set_style('whitegrid')
```

Import Dataset

```
In [2]: dataset = pd.read_csv('./dataset/knn_datasets.csv')
```

Exploratory Data Analysis (EDA) and Statistical Analysis

Kita melihat gambaran umum dataframe kita terlebih dahulu.

Kita mengidentikasi data types, columns names, null value counts, dan memory usage.

0 29.0 0.263 29

4 11 143 94.0 33 146 36.6 0.254 51

```
In [4]:
          dataset.shape
         (480, 9)
Out[4]:
In [5]:
          dataset.info(verbose=True)
         <class 'pandas.core.frame.DataFrame'>
         RangeIndex: 480 entries, 0 to 479
         Data columns (total 9 columns):
              Column Non-Null Count Dtype
          0
              X1
                      480 non-null
                                       int64
              X2
                      480 non-null
                                       int64
          1
              Х3
                      479 non-null
                                       float64
                      480 non-null
          3
              Х4
                                       int64
              X5
                      480 non-null
                                       int64
          5
              X6
                      480 non-null
                                       float64
              X7
                      480 non-null
                                       float64
          7
              X8
                      480 non-null
                                       int64
              Χ9
                      480 non-null
                                       int64
         dtypes: float64(3), int64(6)
         memory usage: 33.9 KB
        Kita berusaha melihat detail dari setiap feature.
```

In [6]:

dataset.describe().T

Out[6]:

	count	mean	std	min	25%	50%	75%	max
X1	480.0	3.779167	3.335327	0.000	1.000	3.000	6.0000	17.00
X2	480.0	121.087500	32.312033	0.000	99.750	117.000	142.0000	197.00
Х3	479.0	69.033403	19.100344	0.000	64.000	70.000	80.0000	122.00
X4	480.0	20.714583	15.632784	0.000	0.000	23.000	33.0000	63.00
X5	480.0	79.135417	114.186313	0.000	0.000	36.500	122.7500	744.00
Х6	480.0	32.022083	8.145896	0.000	27.075	32.000	36.6000	67.10
Х7	480.0	0.485019	0.337495	0.078	0.254	0.384	0.6455	2.42

	count	mean	std	min	25%	50%	75%	max
X8	480.0	32.916667	11.606336	21.000	24.000	29.000	39.0000	81.00
Х9	480.0	0.352083	0.478118	0.000	0.000	0.000	1.0000	1.00

Missing Value Treatment

Dengan menganalisis detail feature di atas, kita menemukan bahwa beberapa feature memiliki nilai nol karena terdapat beberapa feature yang memiliki kisaran nilai yang tidak wajar.

Fitur di bawah ini memiliki nilai nol yang tidak valid:

- X2
- X3
- X4
- X5
- X6

Jadi, kita akan mengganti angka nol ini dengan NaN agar mudah untuk menghitung nilai yang hilang.

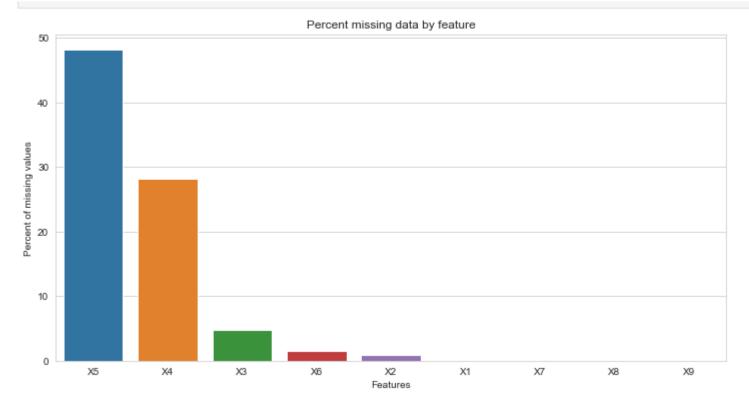
	X1	X2	Х3	Х4	X5	Х6	Х7	X8	Х9
0	3	126.0	88.0	41.0	235.0	39.3	0.704	27	0
1	8	99.0	84.0	NaN	NaN	35.4	0.388	50	0
2	7	196.0	90.0	NaN	NaN	39.8	0.451	41	1
3	9	119.0	80.0	35.0	NaN	29.0	0.263	29	1
4	11	143.0	94.0	33.0	146.0	36.6	0.254	51	1

Kita coba melihat persentase nilai NaN untuk setiap feature.

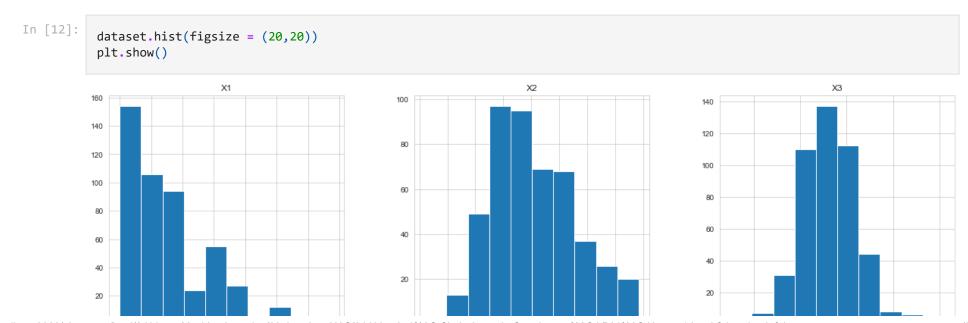
```
total = dataset.isnull().sum().sort_values(ascending=False)
percent = ((dataset.isnull().sum()/dataset.isnull().count())*100).sort_values(ascending=False)
missing_data = pd.concat([total, percent], axis=1, keys=['Total', 'Percent'])
missing_data.head(9)
```

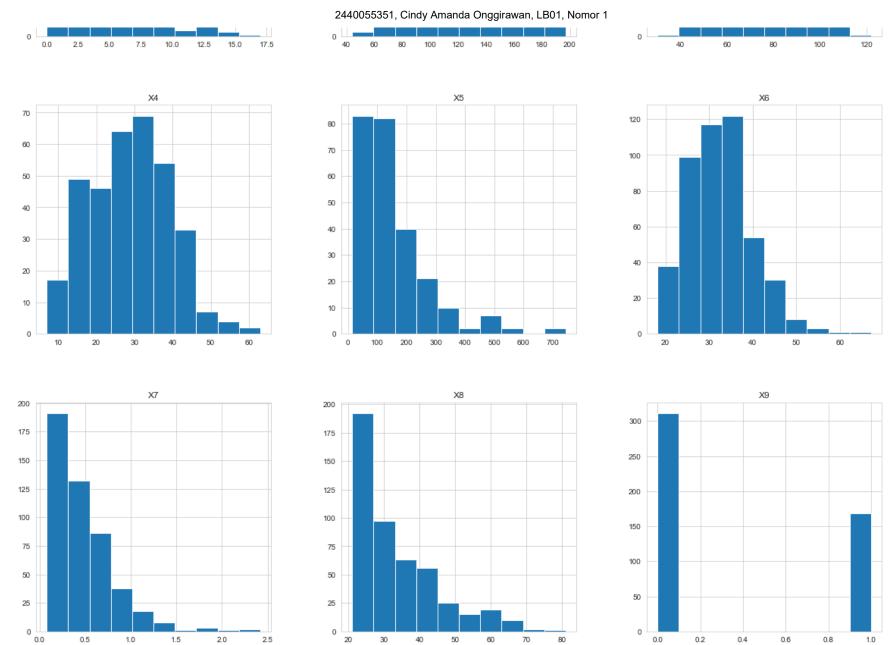
```
Out[10]:
               Total
                       Percent
                231 48.125000
           X5
                135 28.125000
           X4
           X3
                      4.791667
           X6
                      1.458333
           X2
                      0.833333
           X1
                      0.000000
           X7
                      0.000000
           X8
                      0.000000
           X9
                      0.000000
```

```
f, ax = plt.subplots(figsize=(12, 6))
sns.barplot(x=missing_data.index, y=missing_data['Percent'])
plt.title('Percent missing data by feature')
plt.xlabel('Features')
plt.ylabel('Percent of missing values')
plt.show()
```



Understand Data Distribution



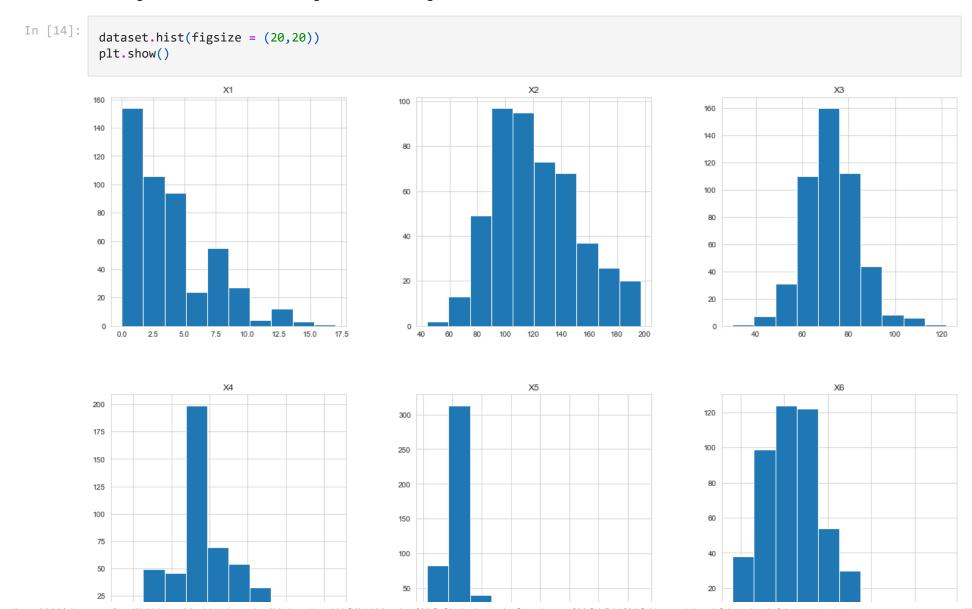


Grafik diatas menunjukkan bahwa feature X2 dan X3 hampir mendekati normal distribution sedangkan X4, X5, dan X6 berbentuk positive skewed. Jadi, kita akan mengganti nilai yang hilang sesuai dengan distribusinya.

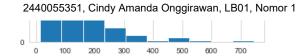
- Jika mendekati normal distribution, maka isi NaN dengan mean-nya.
- Jika berbentuk positive skewed, maka isi NaN dengan median-nya.

```
In [13]:
    dataset['X2'].fillna(dataset['X2'].mean(), inplace = True)
    dataset['X3'].fillna(dataset['X3'].mean(), inplace = True)
    dataset['X4'].fillna(dataset['X4'].median(), inplace = True)
    dataset['X5'].fillna(dataset['X5'].median(), inplace = True)
    dataset['X6'].fillna(dataset['X6'].median(), inplace = True)
```

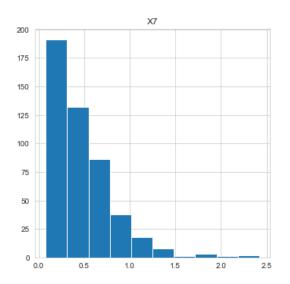
Sekarang, kita coba melihat kembali grafik setelah mengisi NaN.

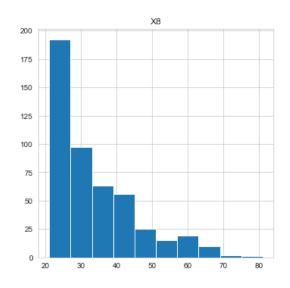


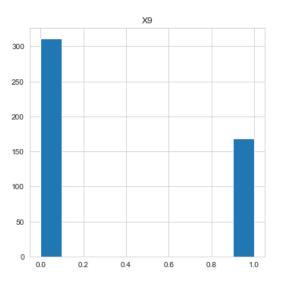












Kita berhasil mengubah feature X2, X3, X4, X5, dan X6 mendekati normal distribution.

Feature Selection

Kita perlu menghitung correlation antara independent variable dan dependent variable.

In [15]:

dataset.corr()

Out[15]:

	X1	X2	Х3	X4	X5	Х6	Х7	X8	Х9
X1	1.000000	0.181010	0.167031	0.103035	0.054359	0.039735	-0.041453	0.542114	0.226904
Х2	0.181010	1.000000	0.180969	0.197794	0.423308	0.244353	0.151050	0.295736	0.464020
Х3	0.167031	0.180969	1.000000	0.191416	0.050763	0.300900	-0.021383	0.316782	0.161057
X4	0.103035	0.197794	0.191416	1.000000	0.223988	0.573104	0.112891	0.102762	0.215599
X5	0.054359	0.423308	0.050763	0.223988	1.000000	0.224863	0.194677	0.073796	0.185890
Х6	0.039735	0.244353	0.300900	0.573104	0.224863	1.000000	0.138555	0.016722	0.331095
X7	-0.041453	0.151050	-0.021383	0.112891	0.194677	0.138555	1.000000	0.033701	0.177169

	X1	X2	Х3	X4	X5	Х6	Х7	X8	Х9
Х8	0.542114	0.295736	0.316782	0.102762	0.073796	0.016722	0.033701	1.000000	0.195662
Х9	0.226904	0.464020	0.161057	0.215599	0.185890	0.331095	0.177169	0.195662	1.000000

Untuk mempermudah, kita gunakan heatmap dan membandingkan korelasi dengan setiap kolom dengan warna.

```
plt.figure(figsize=(12,10))
    sns.heatmap(dataset.corr(), annot=True, cmap='viridis', linewidths=.1)
    plt.show()
```



Semua feature tampak berkorelasi positif dengan target X9.

```
X4 0.215599

X1 0.226904

X6 0.331095

X2 0.464020

X9 1.000000

Name: X9, dtype: float64
```

Akibat dari nilai correlation yang kecil (dibawah 0.5) maka kita putuskan untuk menentukan nilai threshold berdasarkan rata-rata nilai correlation, bukan nilai absolut.

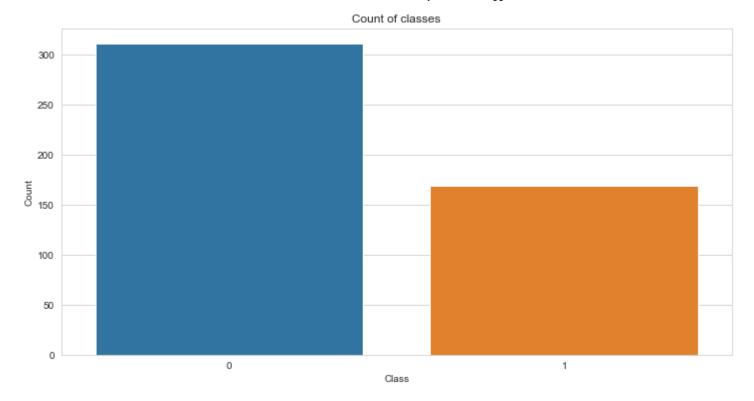
Hanya feature X2 dan X6 yang highly correlated dengan target X9. Berarti, kita akan menghapus semua feature lain selain kedua ini. Namun, kita masih harus memastikan bahwa independent variables ini harus tidak berkolerasi satu sama lain. Jika ternyata indepent variables ini berkorelasi satu sama lain, maka kita hanya perlu menyimpan salah satunya dan membuang sisanya.

Ternyata, X2 dan X6 tidak highly correlated satu sama lain, berarti inilah feature final yang diberikan oleh Pearson correlation. Kita dapat mengambil kedua feature ini untuk dipasangkan dengan target X9.

```
In [22]:
          dataset = dataset.drop(['X1', 'X3', 'X4', 'X5', 'X7', 'X8'], axis = 1)
In [23]:
          dataset
Out[23]:
                X2 X6 X9
           0 126.0 39.3 0
              99.0 35.4
           2 196.0 39.8
           3 119.0 29.0
           4 143.0 36.6
         475 166.0 26.6
         476 110.0 26.0
              81.0 30.1
         478 195.0 25.1
         479 154.0 29.3 0
        480 rows × 3 columns
```

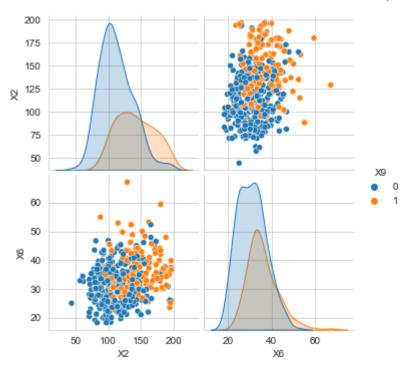
Checking Balance of Data

```
plt.figure(figsize=(12,6))
sns.countplot(x='X9',data=dataset)
plt.title("Count of classes")
plt.xlabel('Class')
plt.ylabel('Count')
plt.show()
```

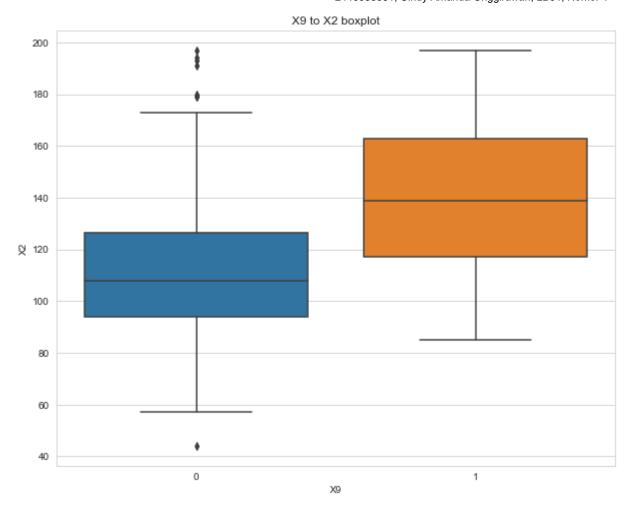


Grafik diatas menunjukkan bahwa dataset bias terhadap class 0. Jumlah data dengan kelas 0 hampir dua kali lipat jumlah data dengan class 1.

```
In [25]:
    sns.pairplot(dataset, hue='X9')
    plt.show()
```

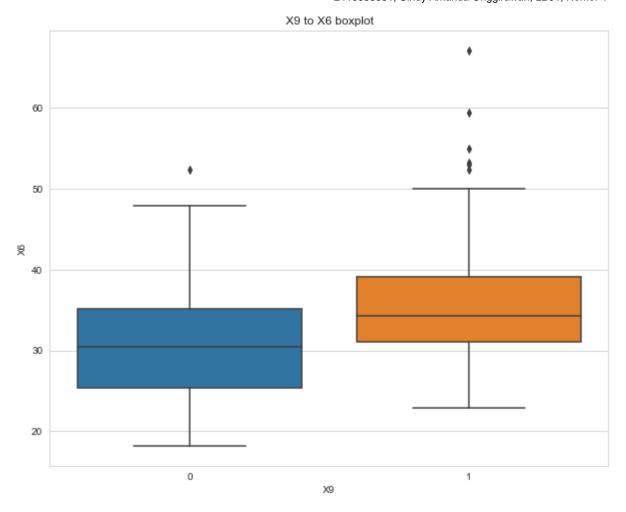


```
plt.figure(figsize=(10,8))
sns.boxplot(data = dataset, x = 'X9', y = 'X2')
plt.title('X9 to X2 boxplot')
plt.show()
```



Kita melihat bahwa class 0 memiliki nilai X2 yang lebih rendah dari class 1, hal ini terlihat dari nilai mediannya yang lebih kecil. Jumlah outliers class 0 juga lebih banyak daripada class 1.

```
plt.figure(figsize=(10,8))
sns.boxplot(data = dataset, x = 'X9', y = 'X6')
plt.title('X9 to X6 boxplot')
plt.show()
```



Kita melihat bahwa class 0 memiliki nilai X6 yang lebih rendah dari class 1, hal ini terlihat dari nilai mediannya yang lebih kecil. Namun, jumlah outliers class 0 lebih sedikit daripada class 1.

Defining Standard Scaler from Scratch

```
class StandardScaler():
    def __init__(self):
        pass

def fit(self, X):
        self.mean_ = np.mean(X, axis=0)
        self.scale_ = np.std(X - self.mean_, axis=0)
        return self
```

```
def transform(self, X):
    return (X - self.mean_) / self.scale_

def fit_transform(self, X):
    return self.fit(X).transform(X)
```

Standardize the Variables

```
In [29]:
           scaled_features = StandardScaler().fit_transform(dataset.drop('X9',axis=1))
In [30]:
           scaled_features
Out[30]:
                    X2
                              X6
            0 0.128505
                         0.952952
            1 -0.762297 0.407075
            2 2.437993 1.022936
            3 -0.102444 -0.488723
              0.689381 0.575037
          475 1.448213 -0.824648
          476 -0.399378 -0.908629
          477 -1.356166 -0.334758
          478 2.405001 -1.034600
          479 1.052300 -0.446733
         480 rows × 2 columns
In [31]:
           target = dataset['X9']
In [32]:
           target
```

In [38]:

class KNN:

def __init__(self, k = 3):

self.k = k

```
Out[32]:
                 1
                 1
          475
          476
          477
                 1
          478
          479
          Name: X9, Length: 480, dtype: int64
In [33]:
          X, y = scaled features.to numpy(), target.to numpy()
         Train Test Split
In [34]:
          from sklearn.model_selection import train_test_split
          X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25, random_state=42)
In [35]:
          X_train.shape
          (360, 2)
Out[35]:
In [36]:
          y_train.shape
          (360,)
Out[36]:
         Defining KNN from Scratch
In [37]:
          def euclidean_distance(x1, x2):
               return np.sqrt(np.sum((x1-x2)**2))
```

```
def fit(self, X, y):
   self.X train = X
   self.y train = y
def predict(self, X):
   predicted labels = [self. predict(x) for x in X]
   return np.array(predicted labels)
def predict(self, x):
   #Hitung jarak dari sebuah titik ke semua titik di x train
   distances = [euclidean distance(x, x train) for x train in self.X train]
   #Ambil sejumlah k titik dengan jarak terdekat dan simpan dalam bentuk indeks angka
   k indices = np.argsort(distances)[:self.k]
   #Tampung label prediksi
   k nearest labels = [self.y train[i] for i in k indices]
   #Tentukan kelas berdasarkan suara terbanyak
   freq0 = 0
   freq1 = 0
   for target in k nearest labels:
       if(target == 0): freq0+=1
       else: freq1+=1
   if(freq0 > freq1): return 0
   else: return 1
def score(self, X, y):
   pred = knn.predict(X)
   return np.sum(pred == y) / len(y)
```

Choosing a K Value

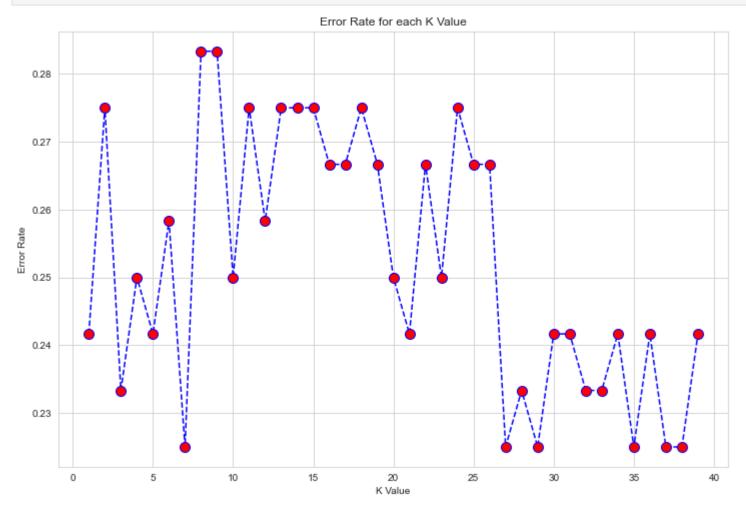
Kita mencari tahu berapa nilai K yang optimal untuk model KNN kita dengan menggunakan elbow method.

```
In [39]:
    error_rate = []
    test_scores = []
    train_scores = []

for i in range(1,40):
        knn = KNN(k = i)
        knn.fit(X_train, y_train)
        pred_i = knn.predict(X_test)
```

```
error_rate.append(np.mean(pred_i != y_test))
train_scores.append(knn.score(X_train, y_train))
test_scores.append(knn.score(X_test, y_test))
```

```
plt.figure(figsize=(12,8))
plt.plot(range(1,40),error_rate,color='blue', linestyle='dashed', marker='o', markerfacecolor='red', markersize=10)
plt.title('Error Rate for each K Value')
plt.xlabel('K Value')
plt.ylabel('Error Rate')
plt.show()
```



Kita dapat lihat bahwa cekungan terdalam yang menunjukkan error rate terendah terdapat pada K = 3. Oleh karena itu, kita mengambil K =

3 untuk digunakan dalam model KNN.

```
In [41]:
         max train score = max(train scores)
          train scores ind = [i for i, v in enumerate(train scores) if v == max train score]
          print('Max train score {} % and k = {}'.format(max train score*100,list(map(lambda x: x+1, train scores ind))))
         Max train score 99.72222222223 % and k = [1]
In [42]:
         max test score = max(test scores)
         test_scores_ind = [i for i, v in enumerate(test_scores) if v == max_test_score]
          print('Max test score \{\} % and k = \{\}'.format(max test score*100,list(map(lambda x: x+1, test scores ind))))
         Max test score 77.5 % and k = [7, 27, 29, 35, 37, 38]
        Predictions
In [43]:
          knn = KNN(k = 7)
In [44]:
          knn.fit(X train, y train)
In [45]:
          y pred = knn.predict(X test)
In [46]:
          y pred
         Out[46]:
                0, 0, 0, 0, 0, 0, 1, 0, 1, 1, 0, 0, 1, 0, 0, 1, 0, 0, 0, 1, 0,
               0, 0, 0, 0, 1, 0, 0, 1, 0, 0, 1, 1, 0, 1, 0, 0, 0, 0, 0, 0, 1,
               0, 1, 0, 1, 0, 1, 1, 0, 0, 1, 0, 1, 0, 0, 0, 0, 0, 1, 1, 0, 0, 0,
               1, 1, 0, 0, 1, 0, 1, 0, 1, 0, 0, 0, 0, 0, 0, 0, 1, 0, 0, 1, 0,
               0, 0, 0, 1, 0, 0, 0, 0, 0, 1])
        Evaluations
In [47]:
          i = 0
          TP = 0
          TN = 0
          FP = 0
          FN = 0
```

for y actual in y test:

TP+=1

if (y pred[i] == 1) and (y actual == 1):

```
elif (y pred[i] == 0) and (y actual == 0):
               elif (y pred[i] == 1) and (y actual == 0):
                  FP+=1
              elif (y_pred[i] == 0) and (y_actual == 1):
                  FN+=1
              i+=1
In [48]:
          accuracy = (TP + TN) / (TP + FP + TN + FN)
          precision = (TP) / (TP + FP)
          recall = (TP) / (TP + FN)
          f1 score = 2 * (precision * recall) / (precision + recall)
In [49]:
          print(f'Accuracy : {str(round(accuracy*100, 2))}%')
          print(f'Precision : {str(round(precision*100, 2))}%')
          print(f'Recall : {str(round(precision*100, 2))}%')
          print(f'F1 Score : {str(round(f1 score*100, 2))}%')
         Accuracy: 77.5%
         Precision : 66.67%
         Recall
                  : 66.67%
         F1 Score : 61.97%
         Model Performance Analysis
In [50]:
          confusion matrix = np.array([[TP, FP], [FN, TN]])
In [51]:
          confusion matrix
         array([[22, 11],
Out[51]:
                 [16, 71]
In [52]:
          matrix df = pd.DataFrame(confusion matrix)
          matrix_df.columns = ['True', 'False']
          matrix df.index = ['True', 'False']
```

```
    In [53]:
    matrix_df

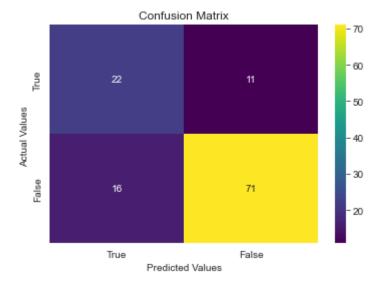
    Out[53]:
    True
    False

    True
    22
    11

    False
    16
    71
```

```
In [54]:
    cm = sns.heatmap(confusion_matrix, annot=True, cmap='viridis')
    cm.set_title('Confusion Matrix');
    cm.set_xlabel('Predicted Values')
    cm.set_ylabel('Actual Values ');

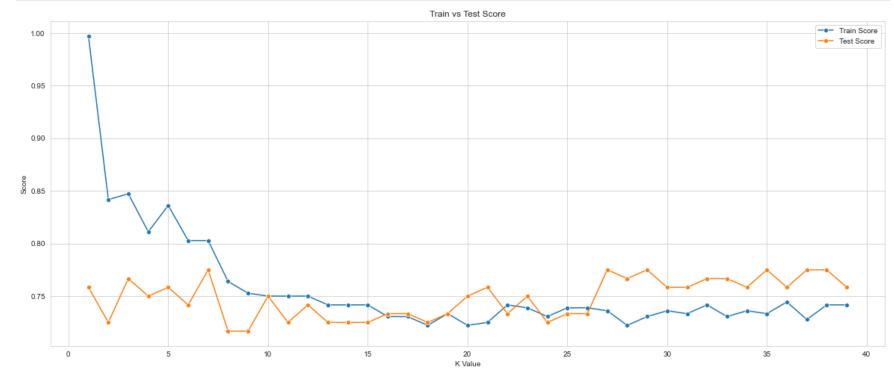
    cm.xaxis.set_ticklabels(['True','False'])
    cm.yaxis.set_ticklabels(['True','False'])
    plt.show()
```



Result Visualisation

Sama seperti sebelumnya, kita buat visualisasi untuk membandingkan akurasi training data dengan testing data, apabila nilai K-nya berubah-ubah.

```
In [55]: plt.figure(figsize=(20,8))
    sns.lineplot(x = range(1,40), y = train_scores, marker = 'o', label = 'Train Score')
    sns.lineplot(x = range(1,40), y = test_scores, marker = 'o', label = 'Test Score')
    plt.title('Train vs Test Score')
    plt.xlabel('K Value')
    plt.ylabel('K Value')
    plt.show()
```



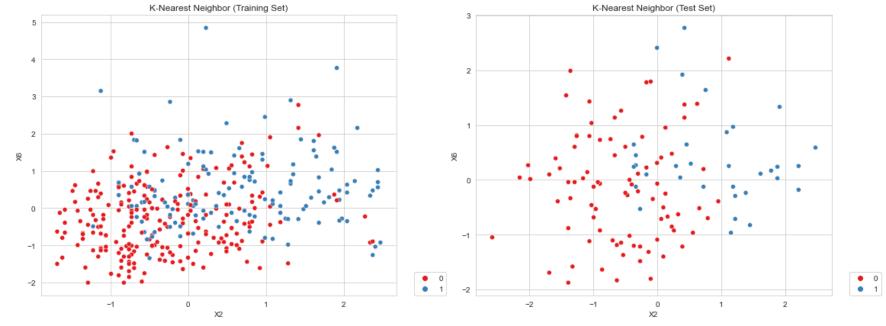
Jika kita melihat garis oranye, maka tampak bahwa K = 7 menyebabkan kestabilan score sampai K = 9. Artinya, ini sejalan dengan teori elbow method yang menentukan nilai K yang menyebabkan score tidak banyak berubah dan cenderung stabil.

```
In [56]: d1 = {'X2': X_train[:,0], 'X6': X_train[:,1], 'X9': y_train}
In [57]: train_dataset = pd.DataFrame(d1)
In [58]: train_dataset.head()
```

```
Out[58]:
                  X2
                           X6 X9
          0 -0.663319
                      0.057154
          1 -0.531349
                      0.575037
          2 -0.828283 -0.740667
          3 -0.861276 -1.412515 0
          4 -0.696312 -1.160572 0
In [59]:
           d2 = {'X2': X_test[:,0], 'X6': X_test[:,1], 'X9': y_pred}
In [60]:
          test dataset = pd.DataFrame(d2)
In [61]:
          test dataset.head()
Out[61]:
                  X2
                           X6 X9
            0.392447 -1.216559
          1 -1.059232 -1.118581 0
            0.524417 0.295100
            0.128505 -0.250777 0
             0.227483 -0.852641
In [62]:
          fig = plt.figure(figsize=(16,6))
           fig.add subplot(1, 2, 1)
           labels = train dataset['X9'].values
           sns.scatterplot(x = X_train[:,0], y = X_train[:,1], hue = labels, palette='Set1')
           plt.legend(loc=(1.05,0))
           plt.title('K-Nearest Neighbor (Training Set)')
           plt.xlabel('X2')
           plt.ylabel('X6')
          fig.add_subplot(1, 2, 2)
```

```
labels = test_dataset['X9'].values
sns.scatterplot(x = X_test[:,0], y = X_test[:,1], hue = labels, palette='Set1')
plt.legend(loc=(1.05,0))
plt.title('K-Nearest Neighbor (Test Set)')
plt.xlabel('X2')
plt.ylabel('X6')

fig.tight_layout()
plt.show()
```



Terima kasih.

2440055351, Cindy Amanda Onggirawan, LB01, Final Exam COMP6745001- Machine Learning

Nomor 2: K-Means

Import Libraries

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
import scipy.stats as stats
sns.set_style('whitegrid')
```

Import Dataset

```
In [2]: dataset = pd.read_csv('./dataset/DNA.csv')
```

Exploratory Data Analysis (EDA) and Statistical Analysis

Kita melihat gambaran umum dataframe kita terlebih dahulu.

```
In [3]: dataset.head()
```

Out[3]:		num_of_atoms	num_of_heavy_atoms
	0	14	6
	1	11	5
	2	15	6
	3	21	7
	4	20	7

Kita mengidentikasi data types, columns names, null value counts, dan memory usage.

```
In [4]:
          dataset.shape
         (14610, 2)
Out[4]:
In [5]:
          dataset.info(verbose=True)
         <class 'pandas.core.frame.DataFrame'>
         RangeIndex: 14610 entries, 0 to 14609
         Data columns (total 2 columns):
              Column
                                  Non-Null Count Dtype
             num of atoms
                                  14610 non-null int64
              num of heavy atoms 14610 non-null int64
         dtypes: int64(2)
         memory usage: 228.4 KB
        Kita berusaha melihat detail dari setiap feature.
```

In [6]: dataset.describe().T

 out[6]:
 count
 mean
 std
 min
 25%
 50%
 75%
 max

 num_of_atoms
 14610.0
 14.412594
 4.693705
 2.0
 11.0
 15.0
 18.0
 33.0

 num_of_heavy_atoms
 14610.0
 5.903285
 1.113774
 2.0
 5.0
 6.0
 7.0
 11.0

Missing Value Treatment

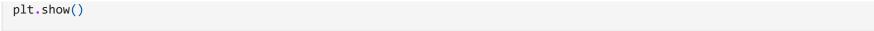
Dengan menganalisis detail feature di atas, kita merasa bahwa kedua feature memiliki kisaran nilai yang masuk akal.

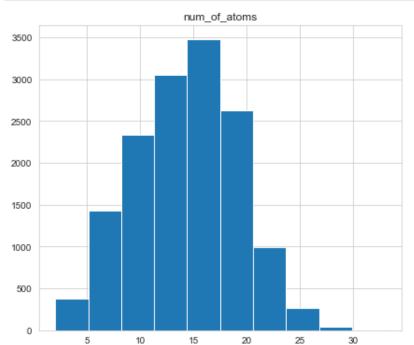
Kita tahu bahwa tidak ada feature yang bernilai kosong, berarti tidak ada yang perlu diisi.

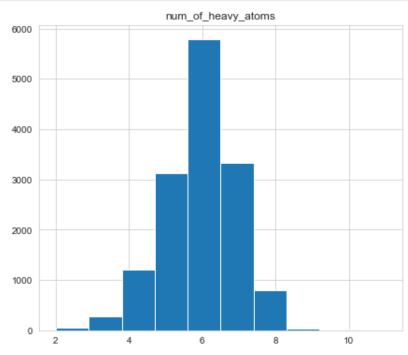
Understand Data Distribution

dtype: int64

In [8]:
dataset.hist(figsize = (16,6))







Grafik diatas menunjukkan bahwa feature num_of_atoms dan num_of_heavy_atoms hampir mendekati normal distribution.

Feature Selection

Kita perlu melihat correlation antara num_of_atoms dan num_of_heavy_atoms. Namun, perlu diperhatikan bahwa feature selection adalah teknik yang terkenal untuk supervised learning, tetapi tidak banyak implementasinya untuk unsupervised learning, seperti clustering ini.

Untuk mempermudah, kita gunakan heatmap dan membandingkan korelasi dengan setiap kolom dengan warna.

```
plt.figure(figsize=(6,4))
sns.heatmap(dataset.corr(), annot=True, cmap='viridis', linewidths=.1)
```



Kedua feature ini berkorelasi positif dan tergolong kuat.

num_of_heavy_atoms

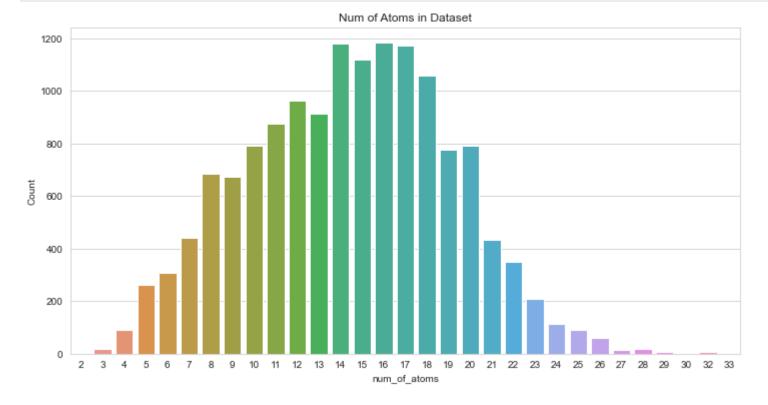
Checking Balance of Data

num_of_atoms

```
In [11]:
          dataset['num_of_atoms'].value_counts().sort_values()
                   1
Out[11]:
          33
                   1
          30
                   3
          29
                   5
          32
                   8
          27
                  14
          3
                  18
          28
                  19
                  59
          26
                  92
          25
                  92
          24
                 112
          23
                 208
          5
                 262
          6
                 308
          22
                 349
                 435
          21
          7
                 442
          9
                 672
          8
                 683
```

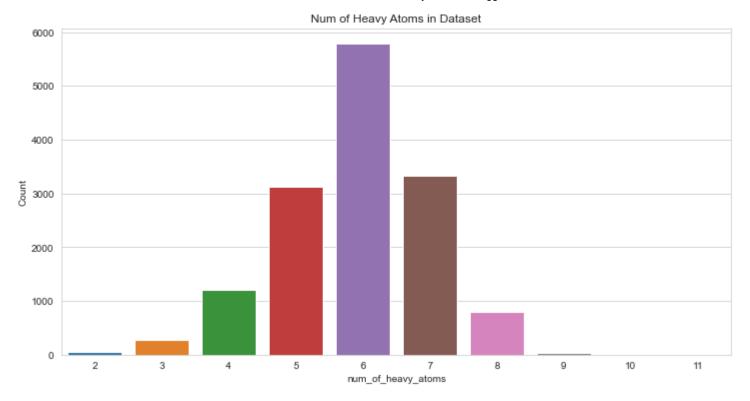
```
19
       776
10
       792
20
       792
11
       874
       915
13
12
       961
18
      1059
15
      1120
17
      1174
14
      1181
16
      1183
Name: num_of_atoms, dtype: int64
```

```
In [12]:
          plt.figure(figsize=(12,6))
          sns.countplot(x='num_of_atoms',data=dataset)
          plt.title("Num of Atoms in Dataset")
          plt.xlabel('num_of_atoms')
          plt.ylabel('Count')
          plt.show()
```



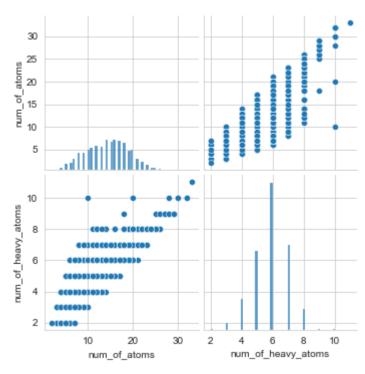
Grafik diatas menunjukkan bahwa data yang memiliki num_of_atoms dari 14-18 masing-masing memiliki count diatas 1000.

```
In [13]:
          dataset['num_of_heavy_atoms'].value_counts().sort_values()
                   1
Out[13]:
                 14
          10
                  42
                  43
                 276
                801
          4
                1203
          5
                3120
          7
                3324
                5786
         Name: num_of_heavy_atoms, dtype: int64
In [14]:
          plt.figure(figsize=(12,6))
          sns.countplot(x='num_of_heavy_atoms',data=dataset)
          plt.title("Num of Heavy Atoms in Dataset")
          plt.xlabel('num_of_heavy_atoms')
          plt.ylabel('Count')
          plt.show()
```

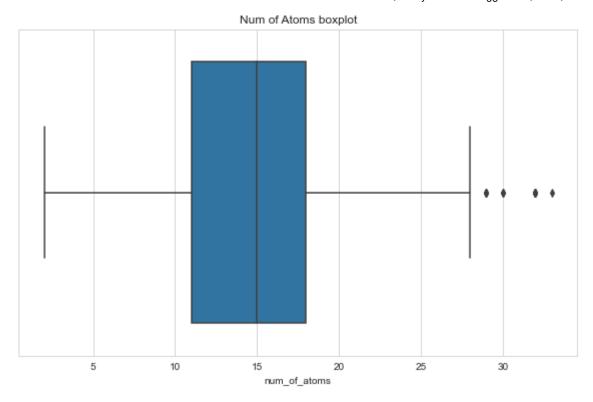


Grafik diatas menunjukkan bahwa num_of_heavy_atoms = 6 yang memiliki jumlah count terbanyak.

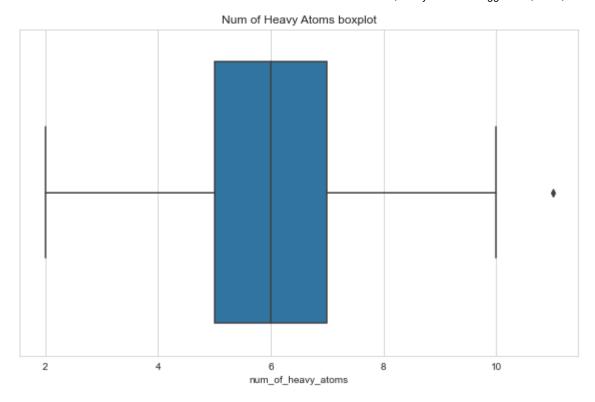
```
In [15]:
    sns.pairplot(dataset)
    plt.show()
```



```
plt.figure(figsize=(10,6))
    sns.boxplot(data = dataset, x = 'num_of_atoms')
    plt.title('Num of Atoms boxplot')
    plt.show()
```



```
plt.figure(figsize=(10,6))
sns.boxplot(data = dataset, x = 'num_of_heavy_atoms')
plt.title('Num of Heavy Atoms boxplot')
plt.show()
```



Defining Standard Scaler from Scratch

```
class StandardScaler():
    def __init__(self):
        pass

def fit(self, X):
        self.mean_ = np.mean(X, axis=0)
        self.scale_ = np.std(X - self.mean_, axis=0)
        return self

def transform(self, X):
        return (X - self.mean_) / self.scale_

def fit_transform(self, X):
    return self.fit(X).transform(X)
```

Standardize the Variables

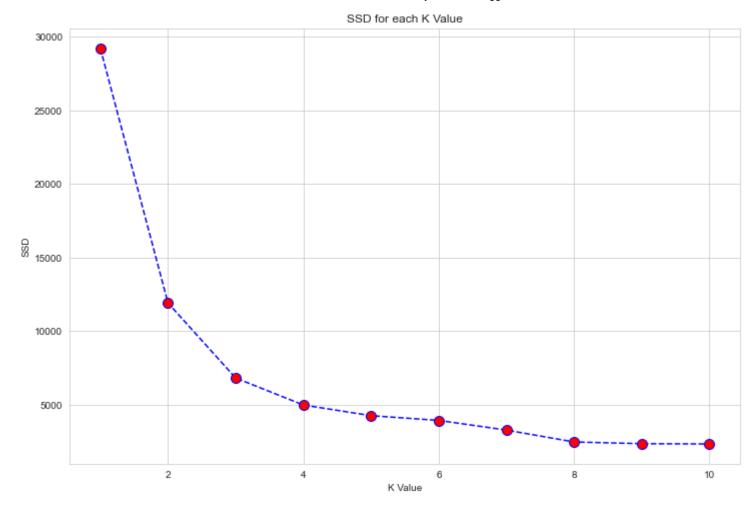
```
scaled_features = StandardScaler().fit_transform(dataset)
In [19]:
In [20]:
           scaled_features
Out[20]:
                 num_of_atoms num_of_heavy_atoms
              0
                      -0.087907
                                          0.086838
                                          -0.811041
                      -0.727083
              2
                      0.125152
                                           0.086838
                                           0.984717
                      1.403504
               4
                      1.190445
                                           0.984717
          14605
                      0.125152
                                           0.086838
          14606
                      -0.087907
                                           0.086838
                      0.764328
          14607
                                           0.086838
          14608
                      0.551269
                                           0.086838
          14609
                      -1.579317
                                          -0.811041
         14610 rows × 2 columns
In [21]:
           X = scaled_features.to_numpy()
In [22]:
           colors = 10*['magenta', 'blue', 'green', 'red']
         Defining K-Means from Scratch
In [23]:
           class K Means:
                def init (self, k=4, tol=0.001, max iter=300):
                    #Tentukan nilai k
                    self.k = k
                    self.tol = tol
                    self.max_iter = max_iter
```

```
def fit(self,data):
   self.centroids = {}
   #Pilih centroid secara acak
   rand idx = np.random.randint(low = 0, high = dataset.shape[0]+1, size = self.k)
   for i in range(self.k):
       self.centroids[i] = data[rand idx[i]]
   for i in range(self.max iter):
       self.classifications = {}
       for i in range(self.k):
            self.classifications[i] = []
       #Expectation: Cocokan setiap titik dengan centroid terdekatnya
       for featureset in data:
            distances = [np.linalg.norm(featureset-self.centroids[centroid]) for centroid in self.centroids]
           classification = distances.index(min(distances))
           self.classifications[classification].append(featureset)
       prev centroids = dict(self.centroids)
       #Maximization: Hitung centroid baru (mean) dari setiap cluster
       for classification in self.classifications:
            self.centroids[classification] = np.mean(self.classifications[classification],axis=0)
       optimized = True
       for c in self.centroids:
            original centroid = prev centroids[c]
            current centroid = self.centroids[c]
           if np.sum((current centroid-original centroid)/original centroid*100.0) > self.tol:
               optimized = False
       #Keluar dari loop jika posisi centroid sudah tidak berubah
       if optimized:
            break
def predict(self,data):
   distances = [np.linalg.norm(data-self.centroids[centroid]) for centroid in self.centroids]
   classification = distances.index(min(distances))
   return classification
```

Choosing a K Value

Kita mencari tahu berapa nilai K yang optimal untuk model KNN kita dengan menghitung sum of squared distances menggunakan elbow method.

```
In [24]:
          ssd = []
          for i in range(1, 11):
              kmeans = K Means(k=i)
              kmeans.fit(X)
              curr ssd = 0
              for featureset in X:
                  distances = []
                  for centroid in kmeans.centroids:
                      distance = np.linalg.norm(featureset-kmeans.centroids[centroid])
                      distances.append(distance)
                  nearest centroid idx = distances.index(min(distances))
                  curr_ssd += (featureset[0] - kmeans.centroids[nearest_centroid_idx][0]) ** 2 + (featureset[1] - kmeans.centroids[
              ssd.append(curr ssd)
In [25]:
          plt.figure(figsize=(12,8))
          plt.plot(range(1, 11), ssd, color='blue', linestyle='dashed', marker='o', markerfacecolor='red', markersize=10)
          plt.title('SSD for each K Value')
          plt.xlabel('K Value')
          plt.ylabel('SSD')
          plt.show()
```



Kita dapat melihat disini jika nilai ssd terbesar ketika K = 1 dan dengan bertambahnya jumlah cluster, nilai ssd akan mulai berkurang. Kita juga dapat melihat bahwa grafik akan berubah dengan cepat pada titik K = 4 dan menciptakan bentuk siku. Dari titik ini, grafik mulai bergerak hampir sejajar dengan sumbu X. Nilai K yang sesuai dengan titik ini adalah nilai K optimal atau jumlah cluster yang optimal.

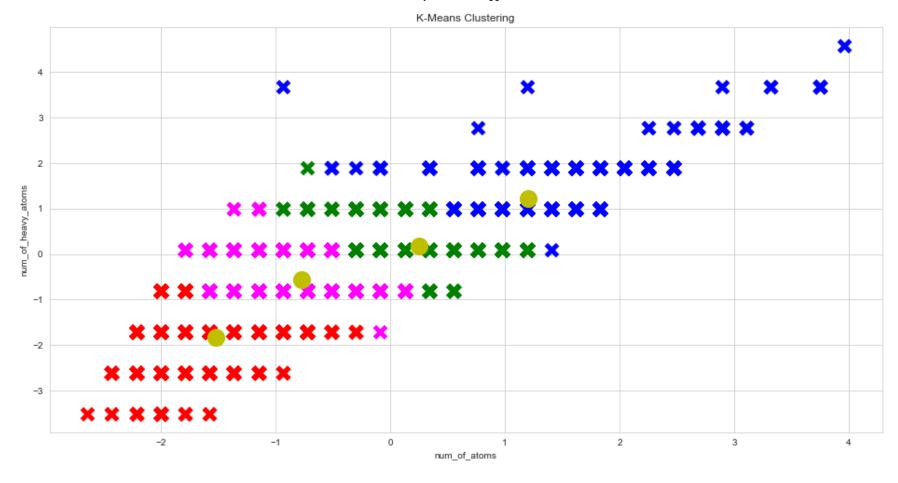
```
6 656.051606
7 809.116151
8 115.108519
9 20.239199
dtype: float64
```

Apabila secara spesifik dihitung perbedaannya, terlihat bahwa:

- titik 1 ke 2 berjarak 17311 dan kemiringannya masih curam.
- titik 2 ke 3 berjarak 5096 dan kemiringannya kurang curam.
- titik 3 ke 4 berjarak 1833 dan kemiringannya mulai stabil disini.

Clustering

```
In [27]:
          kmeans = K Means(k = 4)
          kmeans.fit(X)
In [28]:
          kmeans.centroids
          {0: array([-0.77292865, -0.55696193]),
Out[28]:
          1: array([1.20383055, 1.21355949]),
          2: array([0.24855955, 0.16982226]),
          3: array([-1.52298681, -1.82465436])}
In [29]:
          plt.figure(figsize=(16,8))
          for classification in kmeans.classifications:
               color = colors[classification]
              for featureset in kmeans.classifications[classification]:
                   plt.scatter(featureset[0], featureset[1], marker="x", color=color, s=150, linewidths=5)
          for centroid in kmeans.centroids:
               plt.scatter(kmeans.centroids[centroid][0], kmeans.centroids[centroid][1], marker="o", color="y", s=200, linewidths=5)
          plt.title('K-Means Clustering')
          plt.xlabel('num of atoms')
          plt.ylabel('num of heavy atoms')
          plt.show()
```



Terima kasih.

2440055351, Cindy Amanda Onggirawan, LB01, Final Exam COMP6745001- Machine Learning

Nomor 3: Classification

Import Libraries

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
%matplotlib inline
import seaborn as sns
import scipy.stats as stats
sns.set_style('whitegrid')

In [2]:
import warnings
warnings.filterwarnings('ignore')
```

Import Dataset

```
In [3]: dataset = pd.read_csv('./dataset/experiment.csv')
```

Exploratory Data Analysis (EDA) and Statistical Analysis

Kita melihat gambaran umum dataframe kita terlebih dahulu.

In [4]:	d	dataset.head()															
Out[4]:		F1	F2	F3	F4	F5	F6	F7	F8	F9	F10	•••	F192	F193	F194	F195	F196
	0	0.006711	0.0	0.013423	0.006711	0.0	0.006711	0.006711	0.020134	0.020134	0.000000		0.013423	0.000000	0.006711	0.013423	0.020134
	1	0.000000	0.0	0.000000	0.007246	0.0	0.000000	0.000000	0.021739	0.014493	0.000000		0.007246	0.007246	0.000000	0.000000	0.014493
	2	0.011696	0.0	0.005848	0.000000	0.0	0.005848	0.000000	0.035088	0.017544	0.017544		0.005848	0.000000	0.005848	0.011696	0.035088
	3	0.000000	0.0	0.020833	0.000000	0.0	0.000000	0.010417	0.000000	0.020833	0.000000		0.010417	0.000000	0.000000	0.041667	0.000000

```
F1 F2
                         F3
                                 F4 F5
                                            F6
                                                   F7
                                                           F8
                                                                  F9
                                                                         F10 ...
                                                                                  F192
                                                                                          F193
                                                                                                 F194
                                                                                                         F195
                                                                                                                F196
       5 rows × 201 columns
       Kita mengidentikasi data types, columns names, null value counts, dan memory usage.
In [5]:
        dataset.shape
        (4080, 201)
Out[5]:
In [6]:
        dataset.info(verbose=True)
       <class 'pandas.core.frame.DataFrame'>
       RangeIndex: 4080 entries, 0 to 4079
       Data columns (total 201 columns):
                   Dtype
             Column
        #
                    ____
        0
             F1
                    float64
                    float64
        1
             F2
        2
             F3
                    float64
        3
             F4
                    float64
        4
             F5
                    float64
        5
             F6
                    float64
        6
                    float64
             F7
        7
                    float64
             F8
        8
             F9
                    float64
        9
                    float64
             F10
        10
             F11
                    float64
        11
             F12
                    float64
                    float64
        12
             F13
        13
             F14
                    float64
             F15
                    float64
        14
        15
                    float64
             F16
        16
             F17
                    float64
                    float64
        17
             F18
                    float64
             F19
        18
        19
             F20
                    float64
        20
             F21
                    float64
        21
             F22
                    float64
```

22	F23	float64
23	F24	float64
24	F25	float64
25	F26	float64
26	F27	float64
27	F28	float64
28	F29	float64
29	F30	float64
30	F31	float64
31	F32	float64
32	F33	float64
33	F34	float64
34	F35	float64
35	F36	float64
36	F37	float64
37	F38	float64
38	F39	float64
39	F40	float64
40	F41	float64
41	F42	float64
42	F43	float64
43	F44	float64
44	F45	float64
45	F46	float64
46	F47	float64
47	F48	float64
48	F49	float64
49	F50	float64
50	F51	float64
51	F52	float64
52	F53	float64
53	F54	float64
54	F55	float64
55	F56	float64
56	F57	float64
57	F58	float64
58	F59	float64
59	F60	float64
60	F61	float64
61	F62	float64
62	F63	float64
63	F64	float64
64	F65	float64
65	F66	float64
66	F67	float64

67	F68	float64
68	F69	float64
69	F70	float64
70	F71	float64
71	F72	float64
72	F73	float64
73	F74	float64
74	F75	float64
75	F76	float64
76	F77	float64
77	F78	float64
78	F79	float64
79	F80	float64
80	F81	float64
81	F82	float64
82	F83	float64
83	F84	float64
84	F85	float64
85	F86	float64
86	F87	float64
87	F88	float64
88	F89	float64
89	F90	float64
90	F91	float64
91	F92	float64
92	F93	float64
93	F94	float64
94	F95	float64
95	F96	float64
96	F97	float64
97	F98	float64
98	F99	float64
99	F100	float64
100	F101	float64
101	F102	float64
102	F103	float64
103	F104	float64
104	F105	float64
105	F106	float64
106	F107	float64
107	F108	float64
108	F109	float64
109	F110	float64
110	F111	float64
111	F112	float64

112	F113	float64
113	F114	float64
114	F115	float64
115	F116	float64
116	F117	float64
117	F118	float64
118	F119	float64
119	F120	float64
120	F121	float64
121	F122	float64
122	F123	float64
123	F123	float64
124	F124 F125	float64
125	F125	float64
_		
126	F127	float64
127	F128	float64
128	F129	float64
129	F130	float64
130	F131	float64
131	F132	float64
132	F133	float64
133	F134	float64
134	F135	float64
135	F136	float64
136	F137	float64
137	F138	float64
138	F139	float64
139	F140	float64
140	F141	float64
141	F142	float64
142	F143	float64
143	F144	float64
144	F145	float64
145	F146	float64
146	F147	float64
147	F148	float64
148	F149	float64
149	F150	float64
150	F151	float64
151	F152	float64
152	F153	float64
153	F153 F154	float64
154	F155	float64
155	F156	float64
156	F157	float64

157	F158	float64
158	F159	float64
159	F160	float64
160	F161	float64
161	F162	float64
162	F163	float64
163	F164	float64
164	F165	float64
165	F166	float64
166	F167	float64
167	F168	float64
168	F169	float64
169	F170	float64
170	F171	float64
171	F172	float64
172	F173	float64
173	F174	float64
174	F175	float64
175	F176	float64
176	F177	float64
177	F178	float64
178	F179	float64
179	F180	float64
180	F181	float64
181	F182	float64
182	F183	float64
183	F184	float64
184	F185	float64
185	F186	float64
186	F187	float64
187	F188	float64
188	F189	float64
189	F190	float64
190	F191	float64
191	F192	float64
192	F193	float64
193	F194	float64
194	F195	float64
195	F196	float64
196	F197	float64
197	F198	float64
198	F199	float64
199	F200	float64
200	Class	int64

Out[7]

dtypes: float64(200), int64(1)

memory usage: 6.3 MB

Kita berusaha melihat detail dari setiap feature.

In [7]: dataset.describe().T

	count	mean	std	min	25%	50%	75%	max
F1	4080.0	0.007245	0.012460	0.0	0.0	0.0	0.012500	0.136364
F2	4080.0	0.005094	0.008867	0.0	0.0	0.0	0.009901	0.076923
F3	4080.0	0.003749	0.008527	0.0	0.0	0.0	0.000000	0.150000
F4	4080.0	0.004814	0.008642	0.0	0.0	0.0	0.009009	0.100000
F5	4080.0	0.004394	0.008072	0.0	0.0	0.0	0.008282	0.058824
•••								
F197	4080.0	0.003831	0.007681	0.0	0.0	0.0	0.005723	0.125000
F198	4080.0	0.003890	0.007581	0.0	0.0	0.0	0.006499	0.075000
F199	4080.0	0.004026	0.007857	0.0	0.0	0.0	0.006909	0.050000
F200	4080.0	0.004319	0.008777	0.0	0.0	0.0	0.005579	0.064103
Class	4080.0	3.000000	1.414387	1.0	2.0	3.0	4.000000	5.000000

201 rows × 8 columns

Missing Value Treatment

Dengan menganalisis detail feature di atas, kita merasa bahwa kedua feature memiliki kisaran nilai yang masuk akal.

```
F198 0
F199 0
F200 0
Class 0
Length: 201, dtype: int64
```

Kita tahu bahwa tidak ada feature yang bernilai kosong, berarti tidak ada yang perlu diisi.

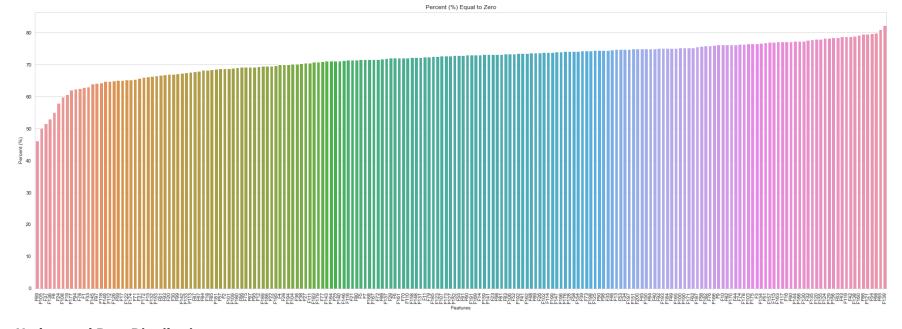
```
In [9]:
           dataset[dataset == 0].count()
                   2567
 Out[9]:
                   2805
          F2
          F3
                   3126
          F4
                   2855
          F5
                   2919
          F197
                   3054
          F198
                   3034
          F199
                   3016
          F200
                   3057
                      0
          Class
          Length: 201, dtype: int64
         Namun, terdapat banyak nilai 0 yang tersebar di berbagai feature.
In [10]:
           def percent_equal_to_zero(dataset):
               percent zero = 100 * dataset[dataset == 0].count() / len(dataset)
               percent zero = percent zero[percent zero > 0].sort values()
               return percent zero
In [11]:
           percent zero = percent equal to zero(dataset)
           percent_zero
          F69
                  46.127451
Out[11]:
          F105
                  50.122549
          F37
                  51.666667
          F136
                  53.112745
          F8
                  55.147059
          F121
                  79.607843
          F54
                  79.656863
          F68
                  79.901961
```

F65 81.004902 F139 82.254902

Length: 200, dtype: float64

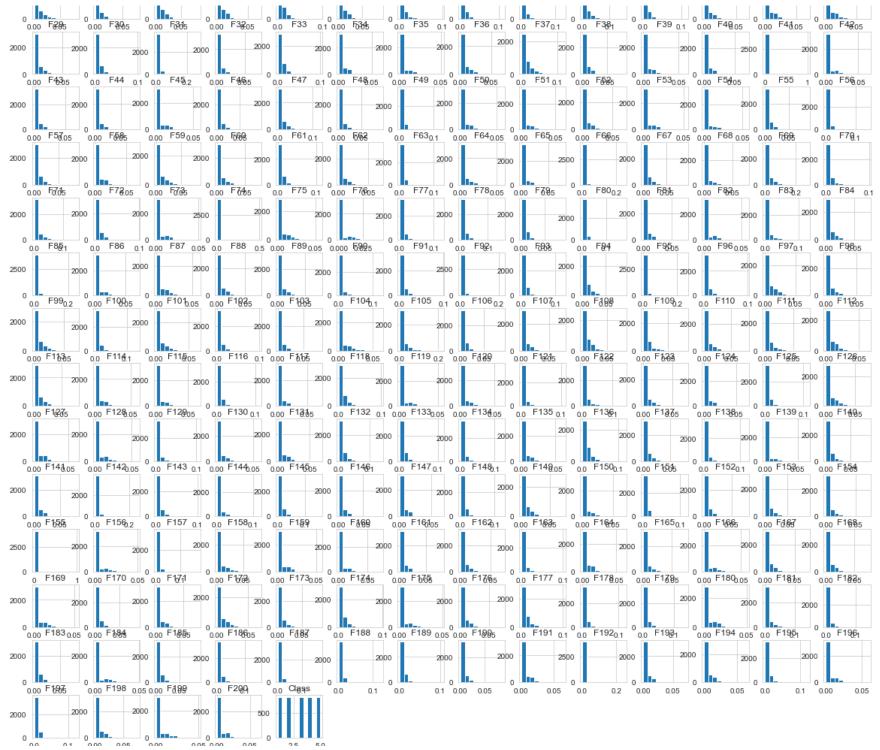
Semua features memiliki data yang bernilai 0, bahkan ada yang mencapai 80% dari keseluruhan data dalam kolom tersebut

```
plt.figure(figsize=(30, 10))
    sns.barplot(x=percent_zero.index,y=percent_zero)
    plt.title('Percent (%) Equal to Zero')
    plt.xlabel('Features')
    plt.ylabel('Percent (%)')
    plt.xticks(rotation=90);
```



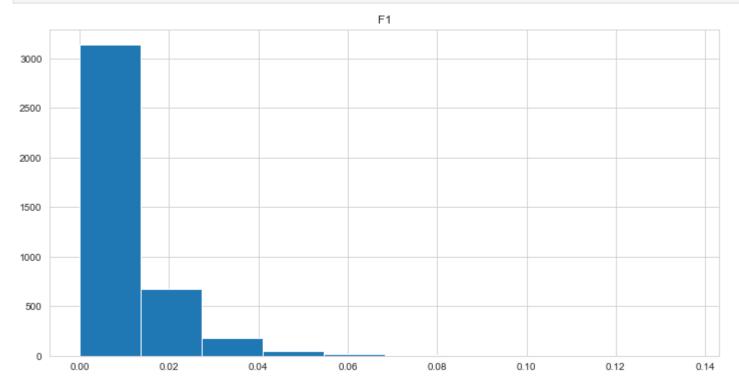
Understand Data Distribution

```
In [13]:
                 dataset.hist(figsize = (20,20))
                 plt.show()
                                       F2
                                                    F3
                                                                  F4
                                                                                F5
                                                                                              F6
                                                                                                            F7
                                                                                                                          F8
                                                                                                                                        F9
                                                                                                                                                     F10
                                                                                                                                                                   F11
                                                                                                                                                                                 F12
                                                                                                                                                                                               F13
                                                                                                                                                                                                             F14
               2000
                                                         2000
                                                                                                                                                           2000
                                                                                                                               2000
                                           2000
                                                                                                                                             2000
                                                                                                                                                                                       2000
                                              0
                                                            0
                                0.00 F1/95
                                               0.0 F1<sub>0</sub>7.1
                                                            0.0 F18 0.1 0.00 F190.05
                                                                                        0.0 F20 0.1 0.00 F2d05
                                                                                                                   0.00 5.83
                                                                                                                                                0.0 F24.1
                                                                                                                                                              0.00 Fo265
                                                                                                                                   0.0 F23<sub>0.1</sub>
                                                                                                                                                                            ັ<sub>0.00</sub> F2,6<sub>05</sub>
                                                                       2000
                                                                                                                                                                                                    2000
               2000
                                            2000
                                                         2000
                                                                                     2000
                                                                                                                                             2000
                                                                                                                                                                                       2000
                                                                                                   2000
                                                                                                                               2000
```



Karena 200 fitur memiliki pola data yang sama, maka kita cukup melakukan generalisasi dengan memvisualisasikan fitur pertama, yaitu F1.

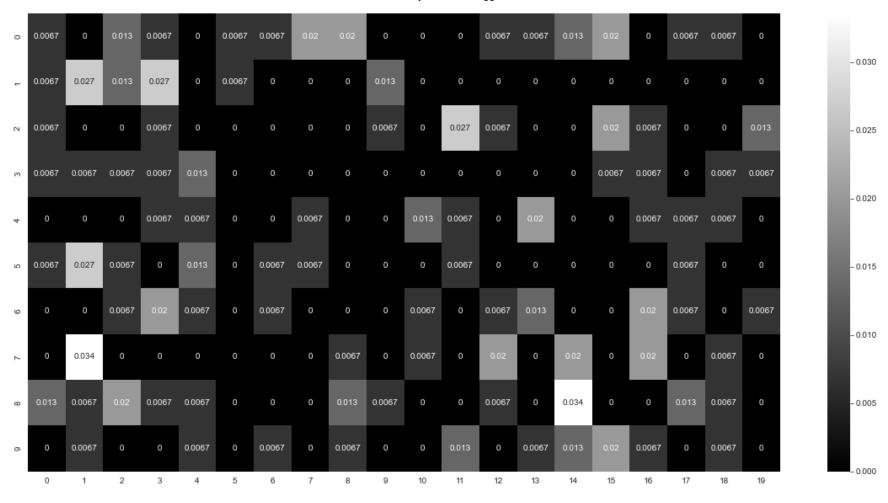
```
dataset['F1'].hist(figsize = (12,6))
plt.title('F1')
plt.show()
```



Grafik diatas menunjukkan bahwa sebagian besar data F1 hampir mendekati 0 dan berbentuk positive skewed.

Setelah mencoba untuk menampilkan visualisasi feature, sekarang kita coba membuat grafik untuk 1 baris data tertentu dan mengeneralisasi 4079 baris lainnya.

```
F3
                 0.013423
         F4
                 0.006711
         F5
                 0.000000
                   . . .
         F196
                 0.020134
         F197
                 0.006711
         F198
                 0.000000
         F199
                 0.006711
         F200
                 0.000000
         Name: 0, Length: 200, dtype: float64
In [17]:
          single data.to numpy().shape
         (200,)
Out[17]:
In [18]:
          single data.to numpy().reshape(10,20)
                                 , 0.01342282, 0.00671141, 0.
         array([[0.00671141, 0.
Out[18]:
                 0.00671141, 0.00671141, 0.02013423, 0.02013423, 0.
                         , 0.
                                       , 0.00671141, 0.00671141, 0.01342282,
                 0.02013423, 0.
                                       , 0.00671141, 0.00671141, 0.
                [0.00671141, 0.02684564, 0.01342282, 0.02684564, 0.
                 0.00671141, 0.
                                       , 0.
                                                   , 0.
                                                               , 0.01342282,
                                       , 0.
                                                   , 0.
                 0.
                                                               , 0.
                                       , 0.
                                                   , 0.
                                       , 0.
                [0.00671141, 0.
                                                  , 0.00671141, 0.
                                       , 0.
                                                   , 0.
                                                               , 0.00671141,
                           , 0.02684564, 0.00671141, 0.
                                                               , 0.
                 0.02013423, 0.00671141, 0.
                                                               , 0.01342282],
                                                   , 0.
                [0.00671141, 0.00671141, 0.00671141, 0.00671141, 0.01342282,
                           , 0.
                                       , 0.
                 0.
                                                   , 0.
                           , 0.
                                       , 0.
                                                  , 0.
                 0.00671141, 0.00671141, 0.
                                                   , 0.00671141, 0.00671141],
                           , 0.
                                                  , 0.00671141, 0.00671141,
                                       , 0.
                [0.
                           , 0.
                                       , 0.00671141, 0.
                 0.01342282, 0.00671141, 0.
                                              , 0.02013423, 0.
                           , 0.00671141, 0.00671141, 0.00671141, 0.
                [0.00671141, 0.02684564, 0.00671141, 0.
                                                              , 0.01342282,
                 0.
                           , 0.00671141, 0.00671141, 0.
                                                               , 0.
                           , 0.00671141, 0.
                                             , 0.
                 0.
                                   , 0.00671141, 0.
                           , 0.
                                     , 0.00671141, 0.02013423, 0.00671141,
                [0.
                 0.
                           , 0.00671141, 0. , 0.
                                                               , 0.
```



Informasi yang kita peroleh sama dengan grafik batang sebelumnya, yaitu setiap data memuat banyak feature yang bernilai 0, yang ditandai dengan warna hitam.

Correlation

Kita perlu menghitung correlation antara independent variable dan dependent variable.



	F1	F2	F3	F4	F5	F6	F7	F8	F9	F10	•••	F192	F193	
F2	0.062642	1.000000	-0.068749	0.021577	0.076734	0.025676	-0.017032	-0.006521	-0.030620	-2.652480e- 02		-0.024747	-0.009527	0.0
F3	-0.033671	-0.068749	1.000000	-0.050458	-0.035755	-0.034025	-0.049696	-0.088605	0.085910	-1.317400e- 02		0.177315	-0.007673	-0.1
F4	0.009647	0.021577	-0.050458	1.000000	0.025955	0.024615	0.011098	-0.003480	-0.045377	3.094654e- 02		-0.058337	0.001371	0.0
F5	0.057143	0.076734	-0.035755	0.025955	1.000000	0.161424	0.058923	-0.006961	0.055993	-4.006644e- 02		-0.027651	-0.057030	0.0
•••														
F197	-0.027931	-0.010725	0.086427	0.021453	-0.055358	-0.053639	-0.005306	-0.061777	0.014667	1.479263e- 02		0.082560	-0.022100	-0.1
F198	-0.028397	0.083870	-0.053308	-0.014131	0.019856	0.099709	-0.006233	-0.084724	-0.053033	-3.131133e- 02		-0.020317	0.050680	-0.
F199	-0.007867	-0.033720	0.096942	-0.004262	-0.017213	0.007877	-0.044835	-0.081779	0.128999	2.835366e- 07		0.100440	-0.052859	-0.1
F200	0.021292	0.051830	-0.035988	0.062791	0.004151	0.015164	-0.028651	-0.022038	-0.053442	-5.626099e- 02		0.001951	-0.074896	0.0
Class	0.026725	0.054789	-0.037185	0.111382	0.046696	-0.121490	0.025376	0.011915	-0.035052	-9.831682e- 02		0.015134	-0.011522	-0.

201 rows × 201 columns

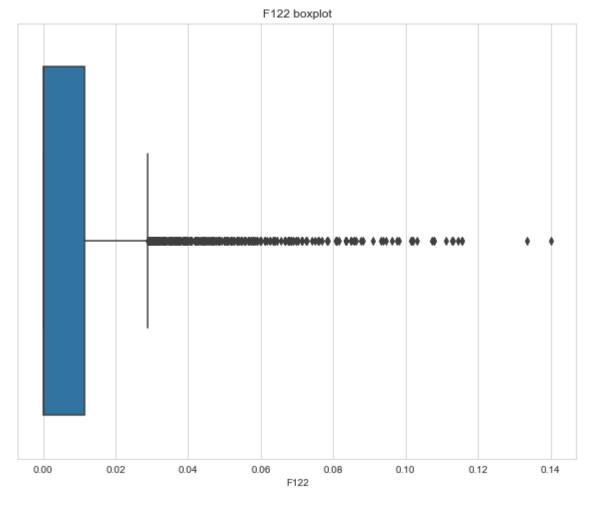
```
In [21]:
          dataset.corr()['Class'].sort_values()
                  -0.214910
         F157
Out[21]:
         F65
                  -0.185885
         F80
                  -0.164355
                  -0.160201
          F13
         F15
                  -0.152490
         F114
                  0.143675
         F12
                  0.164925
                  0.188194
         F200
         F122
                  0.203490
```

```
Class 1.000000
```

Name: Class, Length: 201, dtype: float64

Kita tidak dapat menggunakan heatmap karena terlalu banyak feature menyebabkan grafik juga sulit dipahami. Tetapi disini, kita memperoleh informasi bahwa correlation tertinggi antara independent variable dan dependent variable dipegang oleh feature F122.

```
plt.figure(figsize=(10,8))
sns.boxplot(data = dataset, x = 'F122')
plt.title('F122 boxplot')
plt.show()
```



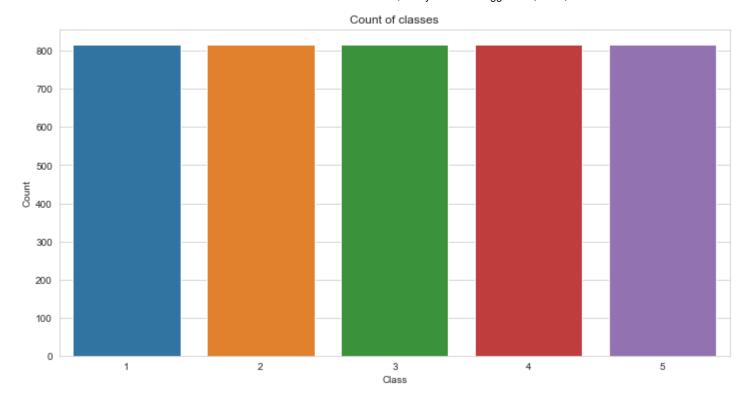
```
In [23]: dataset['F122'].describe().T
```

```
4080.000000
          count
Out[23]:
                      0.008230
          mean
          std
                      0.016096
          min
                      0.000000
          25%
                      0.000000
          50%
                      0.000000
          75%
                      0.011528
                      0.140000
          max
          Name: F122, dtype: float64
```

Kita melihat banyak sekali outlier. Ini disebabkan oleh sebagian besar data di feature F122 bernilai 0. Sehingga, Q1, Q2, dan Q3-nya pun mendekati 0. Hal ini juga menyebabkan nilai IQR yang kecil.

Checking Balance of Data

```
In [24]:
           dataset['Class'].value_counts()
               816
Out[24]:
               816
          3
               816
               816
               816
          Name: Class, dtype: int64
In [25]:
           plt.figure(figsize=(12,6))
           sns.countplot(x='Class',data=dataset)
           plt.title("Count of classes")
           plt.xlabel('Class')
           plt.ylabel('Count')
           plt.show()
```



Grafik diatas menunjukkan bahwa datanya terbagi dengan merata karena untuk setiap class, ada sebanyak 816 data.

Standarization using StandardScaler

Disini, kita menggunakan standarisasi, bukan normalisasi karena:

- Normalisasi digunakan ketika feature memiliki skala yang berbeda, sedangkan dataset kita memiliki skala yang sama yaitu mendekati 0 dan tidak jauh berbeda satu sama lain.
- Standardisasi tidak terpengaruh oleh outlier karena tidak ada rentang feature yang diubah sebelumnya, sedangkan normalisasi sangat dipengaruhi oleh outlier karena nilai minimum dan maksimum feature digunakan untuk penskalaan.

```
In [26]: from sklearn.preprocessing import StandardScaler
scaler = StandardScaler()

In [27]: X = dataset.drop('Class', axis=1)

In [28]:
```

```
X.head()
                                                                             F10 ...
Out[28]:
                F1 F2
                           F3
                                   F4 F5
                                              F6
                                                      F7
                                                              F8
                                                                      F9
                                                                                       F191
                                                                                               F192
                                                                                                      F193
                                                                                                              F194
                                                                                                                      F195
         0 0.006711 0.0 0.013423 0.006711 0.0 0.006711 0.0 0.006711 0.020134 0.020134 0.000000 ... 0.000000 0.013423 0.000000 0.006711 0.013423
         1 0.000000 0.0 0.000000 0.007246 0.0 0.000000 0.000000 0.021739 0.014493 0.000000 ... 0.000000 0.007246 0.007246 0.000000 0.000000
                                                 0.000000 0.035088 0.017544 0.017544 ... 0.005848 0.005848 0.000000 0.005848 0.011696
         2 0.011696 0.0 0.005848 0.000000 0.0 0.005848
         3 0.000000 0.0 0.020833 0.000000 0.0 0.000000 0.010417 0.000000 0.020833 0.000000 ... 0.000000 0.010417 0.000000 0.041667
         5 rows × 200 columns
In [29]:
         y = dataset['Class']
In [30]:
          v.head()
             1
Out[30]:
             1
             1
         3
             1
         Name: Class, dtype: int64
In [31]:
         scaled X = scaler.fit transform(X)
In [32]:
         scaled X
         array([[-0.0427896 , -0.57454216, 1.13461489, ..., -0.51316937,
Out[32]:
                 0.34179386, -0.49211189],
               [-0.58148916, -0.57454216, -0.43974027, ..., -0.51316937,
                 0.40989316, -0.49211189],
               [0.35729731, -0.57454216, 0.24616297, ..., -0.51316937,
                -0.51254179, -0.49211189],
               [0.6165144, -0.57454216, -0.43974027, ..., 1.45594986,
```

```
-0.51254179, 2.90943485],

[-0.58148916, 1.40425033, 1.61796956, ..., 1.80140944,

-0.51254179, 3.50619755],

[ 0.80241157, -0.57454216, -0.43974027, ..., 1.76150295,

-0.51254179, 3.43726126]])
```

Feature Selection using Principal Component Analysis (PCA)

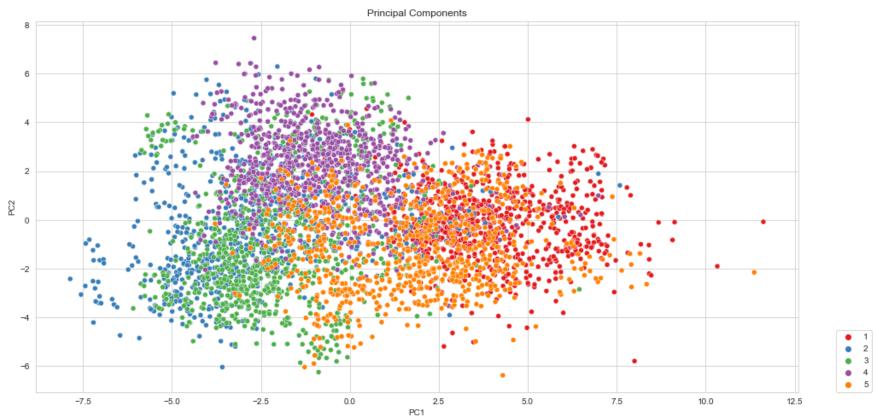
Disini, kita menggunakan PCA karena:

- PCA dapat digunakan ketika dimensi dari feature itu tinggi, contohnya dataset kita terdiri dari 200 independent variables dan 1 dependent variables.
- PCA sangat berguna dalam memproses data di mana terdapat multikolinieritas antara features. Hal ini ditunjukkan dengan korelasi positif dan negatif yang sudah kita hitung sebelumnya.
- PCA juga dapat digunakan untuk denoising dan kompresi data.

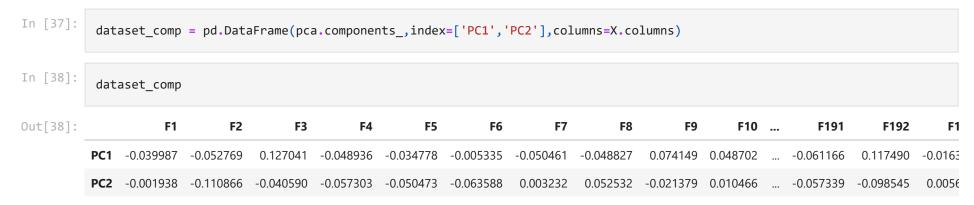
Kita menggunakan 2 komponen saja agar mudah divisualisasikan.

```
In [33]:
          from sklearn.decomposition import PCA
          pca = PCA(n components=2)
In [34]:
          principal components = pca.fit transform(scaled X)
In [35]:
          principal components
         array([[4.59802335, 0.9515533],
Out[35]:
                 [1.57196201, 2.01716509],
                 [2.83304128, 0.81440737],
                 [2.79146941, 1.97687851],
                 [3.69278394, 1.9135366],
                 [3.81918682, 2.33544962]])
In [36]:
          plt.figure(figsize=(16,8))
          labels = dataset['Class'].values
          sns.scatterplot(x = principal components[:,0], y = principal components[:,1], hue = labels, palette = 'Set1')
          plt.legend(loc=(1.05,0))
          plt.title('Principal Components')
          plt.xlabel('PC1')
```



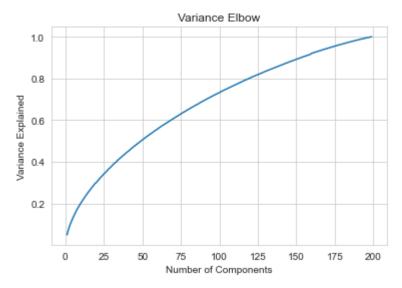


Dibawah ini adalah dataframe yang menjelaskan arah variance maksimum pada dataset dan diurutkan berdasarkan explained variance.



2 rows × 200 columns

```
In [39]:
           pca.explained_variance_ratio_
          array([0.0497773 , 0.02675805])
Out[39]:
         Kita dapat melihat bahwa di ruang PCA, PC1 menjelaskan 4,9% variance dari dataset dan PC2 menjelaskan 2,6% variance dari dataset.
In [40]:
           np.sum(pca.explained_variance_ratio_)
          0.07653534727307632
Out[40]:
         Bersama-sama, mereka menjelaskan 7,6% variance dari dataset. Ini memang tergolong kecil karena kita berusaha mengubah dari 200
         dimensi menjadi 2 dimensi dan kemungkinan ada banyak loss.
In [41]:
           explained_variance = []
           for n in range(1,200):
               pca = PCA(n_components=n)
               pca.fit(scaled X)
               explained_variance.append(np.sum(pca.explained_variance_ratio_))
In [42]:
           plt.plot(range(1,200),explained variance)
           plt.title('Variance Elbow')
           plt.xlabel("Number of Components")
           plt.ylabel("Variance Explained");
           plt.show()
```



Data Visualization

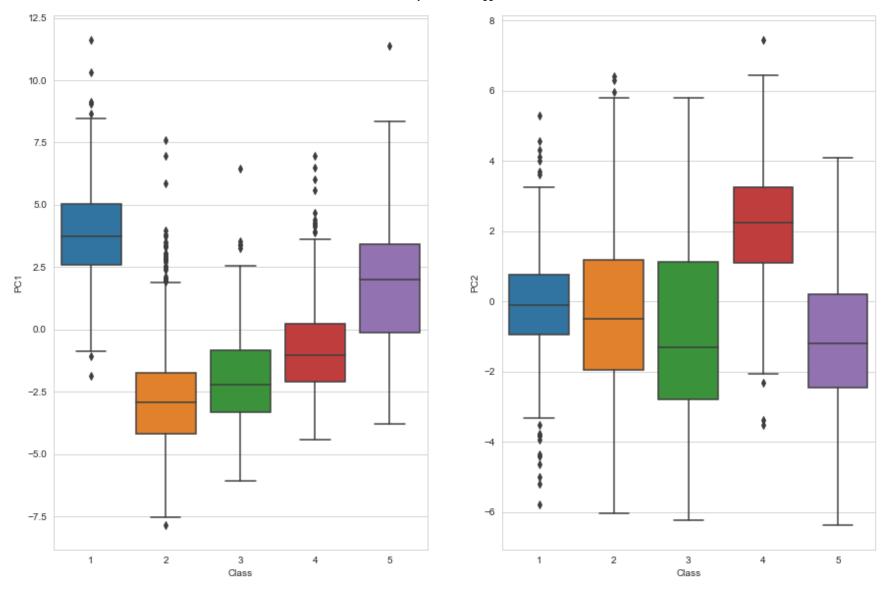
```
In [43]:
           d = {'PC1': principal_components[:,0], 'PC2': principal_components[:,1], 'Class': y}
In [44]:
           new_dataset = pd.DataFrame(d)
In [45]:
           new_dataset
Out[45]:
                   PC1
                             PC2 Class
             0 4.598023
                         0.951553
             1 1.571962 2.017165
             2 2.833041 0.814407
             3 7.025828 -0.176614
             4 7.209296 -1.291620
          4075 3.856432 2.068715
                                     5
          4076 3.654091 2.361181
                                     5
```

	PC1	PC2	Class
4077	2.791469	1.976879	5
4078	3.692784	1.913537	5
4079	3.819187	2.335450	5

4080 rows × 3 columns

```
In [46]: num_list = ['PC1', 'PC2']

In [47]: fig = plt.figure(figsize = (15,10))
    for i in range(len(num_list)):
        column = num_list[i]
        sub = fig.add_subplot(1, 2, i+1)
        sns.boxplot(x = 'Class', y = column, data = new_dataset)
```



Ada banyak outlier di setiap kelas. Namun, kita tidak perlu menghapus outlier kecuali jika ada kesalahan dalam data. Outlier tidak selalu merupakan titik data yang buruk. Terkadang mereka adalah data yang paling penting dari semuanya.

Kita hanya membuat new_X karena tidak ada pengubahan pada y-nya.

```
In [48]:
    new_X = new_dataset.drop(['Class'], axis=1)
```

```
      In [49]:
      PC1 PC2

      0 4.598023 0.951553
      1 1.571962 2.017165

      2 2.833041 0.814407
      3 7.025828 -0.176614

      4 7.209296 -1.291620
```

Dengan menggunakan PCA

Train Test Split

```
In [50]:
          from sklearn.model_selection import train_test_split
           from sklearn import preprocessing
          X_train, X_test, y_train, y_test = train_test_split(new_X, y, test_size=0.25, random_state=101)
In [51]:
          X train.shape
          (3060, 2)
Out[51]:
In [52]:
          y train.shape
          (3060,)
Out[52]:
         Pipeline
In [53]:
           from sklearn.neighbors import KNeighborsClassifier
           from sklearn.tree import DecisionTreeClassifier
           from sklearn.ensemble import RandomForestClassifier
           from sklearn.naive_bayes import GaussianNB
```

```
model_pipeline = []
model_pipeline.append(KNeighborsClassifier())
model_pipeline.append(DecisionTreeClassifier())
model_pipeline.append(RandomForestClassifier())
model_pipeline.append(GaussianNB())
```

Kita tidak memasukkan SVM karena pada umumnya, SVM tidak mendukung classification multiclass secara native. SVM memang mendukung binary classification dan memisahkan titik data menjadi dua kelas. Namun, untuk klasifikasi multiclass, kita butuh tenaga ekstra untuk mengimplementasikan prinsip yang sama, yaitu memecah multiclass classification menjadi beberapa masalah binary classification.

```
In [54]:
          from sklearn import metrics
          from sklearn.metrics import accuracy score
          from sklearn.metrics import precision score
          from sklearn.metrics import recall score
          from sklearn.metrics import f1 score
          from sklearn.metrics import confusion matrix
          from sklearn.metrics import classification report
          model list = ['KNN', 'Decision Tree', 'Random Forest', 'Naive Bayes']
          acc list = []
          prec list = []
          rec list = []
          f1 list = []
          cm_list = []
          for model in model pipeline:
              model.fit(X train, y train)
              y pred = model.predict(X test)
              acc_list.append(accuracy_score(y_test, y_pred))
              prec list.append(precision score(y test, y pred, average='weighted'))
              rec list.append(recall score(y test, y pred, average='weighted'))
              f1 list.append(f1 score(y_test, y_pred, average='weighted'))
              cm list.append(confusion matrix(y test, y pred))
In [55]:
          d = {'Model': model list, 'Accuracy': acc list, 'Precision': prec list, 'Recall': rec list, 'F1 Score': f1 list}
In [56]:
          model evaluation = pd.DataFrame(d)
In [57]:
```

model_evaluation

Out[57]:		Model	Accuracy	Precision	Recall	F1 Score
	0	KNN	0.530392	0.529720	0.530392	0.527318
	1	Decision Tree	0.495098	0.497582	0.495098	0.495517
	2	Random Forest	0.529412	0.522813	0.529412	0.524707
	3	Naive Bayes	0.576471	0.569653	0.576471	0.564802

Evaluation Metrics

Jika kita menggunakan PCA, kita akan menggunakan kedua model dengan akurasi tertinggi yaitu Naive Bayes dan Random Forest.

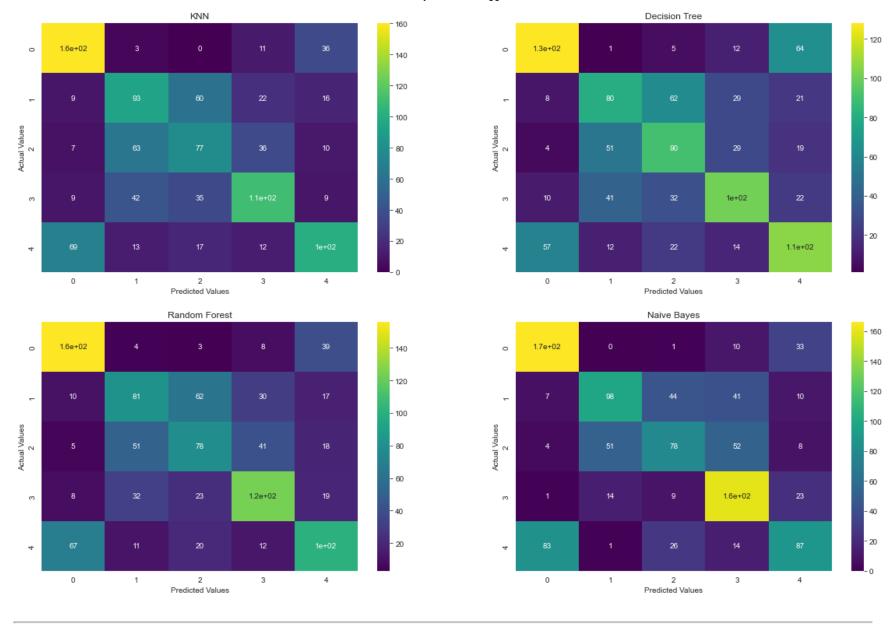
```
In [58]: model_evaluation.nlargest(n=2, columns=['Accuracy', 'Precision', 'Recall', 'F1 Score'])
Out[58]: Model Accuracy Precision Recall F1 Score
```

•		Model	Accuracy	Precision	Recall	F1 Score
	3	Naive Bayes	0.576471	0.569653	0.576471	0.564802
	0	KNN	0.530392	0.529720	0.530392	0.527318

Kita menggunakan Naive Bayes sebab algoritma ini mudah dan cepat untuk memprediksi kelas dari kumpulan data testing. Algoritma ini juga bekerja dengan baik dalam prediksi multiclass dengan jumlah feature yang tidak terlalu banyak. Disebut naif karena mengasumsikan independensi antara setiap pasangan fitur dalam data.

Random Forest juga tidak kalah menarik dengan Naive Bayes karena algoritma ini juga mudah diinterpretasikan. Tetapi, perbedaannya ada Naive Bayes bekerja dengan baik pada kumpulan data yang kecil. Sedangkan, Random Forest bekerja dengan baik pada kumpulan data yang besar dan tidak sensitif terhadap outlier.

```
fig = plt.figure(figsize=(20,20))
for i in range(len(cm_list)):
    cm = cm_list[i]
    model = model_list[i]
    sub = fig.add_subplot(3, 2, i+1).set_title(model)
    cm_plot = sns.heatmap(cm, annot=True, cmap='viridis')
    cm_plot.set_xlabel('Predicted Values')
    cm_plot.set_ylabel('Actual Values')
```



Tanpa menggunakan PCA

Train Test Split

```
from sklearn.model_selection import train_test_split
In [60]:
          from sklearn import preprocessing
          X train, X test, y train, y test = train test split(X, y, test size=0.25, random state=101)
In [61]:
          X train.shape
          (3060, 200)
Out[61]:
In [62]:
          y train.shape
          (3060,)
Out[62]:
         Pipeline
In [63]:
          from sklearn.neighbors import KNeighborsClassifier
          from sklearn.tree import DecisionTreeClassifier
          from sklearn.ensemble import RandomForestClassifier
          from sklearn.naive bayes import GaussianNB
          model pipeline = []
          model pipeline.append(KNeighborsClassifier())
          model_pipeline.append(DecisionTreeClassifier())
          model pipeline.append(RandomForestClassifier())
          model pipeline.append(GaussianNB())
In [64]:
          from sklearn import metrics
          from sklearn.metrics import accuracy score
          from sklearn.metrics import precision score
          from sklearn.metrics import recall score
          from sklearn.metrics import f1 score
          from sklearn.metrics import confusion matrix
          from sklearn.metrics import classification report
          model list = ['KNN', 'Decision Tree', 'Random Forest', 'Naive Bayes']
          acc list = []
          prec list = []
          rec list = []
          f1 list = []
          cm list = []
```

```
for model in model pipeline:
              model.fit(X train, y train)
              y pred = model.predict(X test)
              acc list.append(accuracy score(y test, y pred))
              prec list.append(precision score(y test, y pred, average='weighted'))
              rec list.append(recall score(y test, y pred, average='weighted'))
              f1_list.append(f1_score(y_test, y_pred, average='weighted'))
              cm list.append(confusion matrix(y test, y pred))
In [65]:
          d = {'Model': model list, 'Accuracy': acc list, 'Precision': prec list, 'Recall': rec list, 'F1 Score': f1 list}
In [66]:
          model evaluation = pd.DataFrame(d)
In [67]:
          model evaluation
Out[67]:
                  Model Accuracy Precision
                                             Recall F1 Score
         0
                                  0.916135 0.914706 0.914446
                          0.914706
              Decision Tree 0.682353
                                  2 Random Forest 0.919608
                                  0.920329 0.919608 0.919337
              Naive Bayes 0.786275 0.785520 0.786275 0.785171
```

Evaluation Metrics

Jika kita tidak menggunakan PCA, kita akan menggunakan kedua model dengan akurasi tertinggi yaitu KNN dan Random Forest.

Seperti yang dapat dilihat, KNN mengandalkan kesamaan data yang dapat diamati dan metrik jarak yang canggih untuk menghasilkan prediksi yang akurat. Teknik ini mungkin tampak sedikit berlawanan dengan intuisi dan kita mungkin tidak dapat dipercaya pada awalnya,

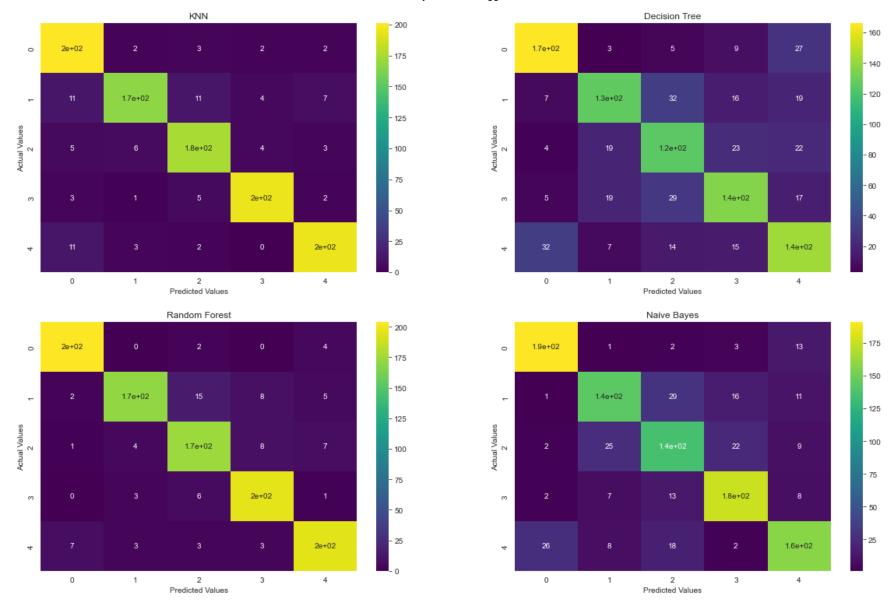
tetapi sebenarnya sangat dapat diandalkan. KNN paling berguna ketika feature data berlabel terlalu banyak, dan dapat mencapai akurasi tinggi dalam berbagai macam masalah tipe prediksi.

Sama seperti model dengan menggunakan PCA, disini, kita juga menggunakan model Random Forest membangun beberapa Decision Tree dan menggabungkannya untuk mendapatkan prediksi yang lebih akurat dan stabil. Kualitas hebat lainnya dari algoritma Random Forest adalah sangat mudah untuk mengukur kepentingan relatif dari setiap feature yang diprediksi. Kita dapat mengetahui pentingnya fitur dengan menghitung skor secara otomatis untuk setiap feature setelah training dan scale hasilnya sehingga jumlah semua kepentingan sama dengan satu.

Mengapa akurasi tanpa menggunakan PCA lebih tinggi daripada menggunakan PCA?

Tentu saja lebih tinggi karena mengurangi feature juga menyebabkan penurunan variance yang menjelaskan data kita secara lebih spesifik. Dalam kasus ini, datanya terbagi secara merata, dimana setiap kelas memiliki 816 data. Sebenarnya, tanpa melakukan preprocessing juga, kita dapat langsung membuat model karena keuntungan ini. Alangkah lebih baik agar setiap feature dilabeli dengan keterangan yang jelas, tidak hanya F1, F2, dst., agar kita tidak semata-mata memilih jumlah komponen PCA, dan memikirkan kepentingan tiap feature.

```
fig = plt.figure(figsize=(20,20))
for i in range(len(cm_list)):
    cm = cm_list[i]
    model = model_list[i]
    sub = fig.add_subplot(3, 2, i+1).set_title(model)
    cm_plot = sns.heatmap(cm, annot=True, cmap='viridis')
    cm_plot.set_xlabel('Predicted Values')
    cm_plot.set_ylabel('Actual Values')
```



Terima kasih.